

T.C.
İNÖNÜ ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

YAPAY ZEKA DERSİ
PROJE ÖN HAZIRLIK VE ARAŞTIRMA RAPORU

Proje Başlığı:
Makine Öğrenmesi ve Özellik Mühendisliği Kullanarak
NASDAQ Hisselerinde Yön Tahmini ve Sınıflandırma

Hazırlayan:
Can Aslan
Öğrenci No: 02230201021
Bilgisayar Mühendisliği

1. Çalışmanın Başlığı

Makine Öğrenmesi ve Özellik Mühendisliği Kullanarak NASDAQ Hisselerinde Yön Tahmini ve Sınıflandırma

2. Özet

Bu çalışma, finansal piyasalardaki zaman serisi verilerinin karmaşık ve doğrusal olmayan yapısı nedeniyle ortaya çıkan hisse senedi yön tahmini problemini akademik bir çerçevede ele almaktadır. Finansal piyasalarda gerçekleştirilen isabetli tahminler; bireysel yatırımcılar, portföy yöneticileri ve algoritmik ticaret sistemleri için kritik bir karar destek mekanizması işlevi görmektedir. Geleneksel regresyon tabanlı kesin fiyat tahminlerinin yüksek varyans ve sapma değerleri sergilediği göz önüne alınarak, bu projede ilgili problem bir makine öğrenmesi sınıflandırma problemi biçiminde yeniden kurgulanmıştır. Söz konusu kurgu çerçevesinde model, bir hisse senedinin ertesi işlem günündeki kapanış fiyatının bugüne kıyasla artış mı yoksa düşüş mü göstereceğini ikili (binary) sınıflandırma yöntemiyle tahmin etmektedir.

Bu bağlamda çalışmada Yapay Sinir Ağları (ANN/MLP) ve Destek Vektör Makineleri (SVM) algoritmaları karşılaştırmalı biçimde incelenmekte ve uygulanmaktadır. Proje kapsamında NASDAQ borsasından elde edilecek Açılış, Kapanış, En Yüksek, En Düşük ve İşlem Hacmi (OHLCV) verilerine; RSI, MACD ve Hareketli Ortalamalar gibi teknik indikatörler türetilerek özellik mühendisliği (feature engineering) aşaması gerçekleştirilecektir. Geliştirilen sınıflandırma modellerinin performansları çok boyutlu metrikler (Accuracy, Precision, Recall, F1-Score, Confusion Matrix) aracılığıyla karşılaştırmalı olarak analiz edilecek; ayrıca modelin pratik uygulanabilirliği sanal hesap (paper trading) ortamında kar/zarar analizi ile sınanacaktır.

3. Giriş

Günümüz bilgi çağında sağlık, eğitim, enerji ve finans başta olmak üzere pek çok sektörde devasa miktarda veri üretilmekte; bu verilerin işlenmesi ve yorumlanması giderek daha kritik bir hal almaktadır. Finansal piyasalar, söz konusu büyük veri ekosistemlerinin en dinamik ve bilgi yoğunluğu en yüksek bileşenlerinden birini oluşturmaktadır [1]. Hisse senedi fiyatlarının öngörülmesi; yatırımcıların risk yönetimi, portföy optimizasyonu ve algoritmik ticaret stratejilerinin geliştirilmesi açısından vazgeçilmez bir öneme sahiptir.

Hisse senedi fiyatlarının oluşum dinamiklerini açıklamaya yönelik iki temel geleneksel yaklaşım bulunmaktadır: Temel Analiz ve Teknik Analiz. Temel analiz; şirketin mali tabloları, bilanço verileri ve sektörel göstergelerini yorumlayarak hissenin içsel değerini hesaplamayı amaçlar. Teknik analiz ise tarihsel fiyat ve işlem hacmi verilerine dayanarak gelecekteki fiyat hareketlerini tahmin etmeye çalışır [6]. Her iki yaklaşımın da belirli sınırlılıkları bulunmakta olup çok boyutlu ve doğrusal olmayan piyasa dinamiklerini yeterince modelleyememektedir.

Mevcut literatür incelendiğinde, finans alanındaki makine öğrenmesi uygulamalarında ağırlıklı olarak Yapay Sinir Ağları (ANN), Destek Vektör Makineleri (SVM), Long Short-Term Memory (LSTM) ağları ve Genetik Algoritmalar ile bunların hibrit kombinasyonlarının kullanıldığı görülmektedir. Bu çalışma; söz konusu algoritmalar arasında sınıflandırma performansı açısından en yaygın olarak öne çıkan SVM ve ANN algoritmalarını esas alarak NASDAQ hisselerinin günlük yön tahminine odaklanmakta ve özellik mühendisliği tekniklerinin model başarısına katkısını sistematik biçimde araştırmaktadır.

4. Problem Tanımı

Bu projede ele alınan temel problem; belirli bir NASDAQ hisse senedinin geçmiş fiyat ve hacim hareketleri analiz edilerek bir sonraki işlem günündeki kapanış fiyatının yönünün tahmin edilmesidir. Problem, aşağıda açıklanan bileşenler çerçevesinde somut biçimde tanımlanmıştır:

- **Giriş Verileri (Özellik Vektörü):** NASDAQ borsasından elde edilecek günlük Açılış (Open), Kapanış (Close), En Yüksek (High), En Düşük (Low) ve İşlem Hacmi (Volume) – kısaca OHLCV – verilerine ek olarak; Göreceli Güç Endeksi (RSI), Hareketli Ortalama Yakınsaklık/İraksama (MACD), Basit ve Üstel Hareketli Ortalamalar (SMA/EMA) gibi teknik indikatörler hesaplanarak genişletilmiş bir özellik vektörü oluşturulacaktır.
- **Çıktı (Hedef Değişken):** Model, t günündeki kapanış fiyatının $t+1$ günündeki kapanış fiyatına kıyasla artış gösterip göstermeyeceğini ikili etiket biçiminde üretecektir: Artış $\rightarrow 1$ (Pozitif), Düşüş $\rightarrow 0$ (Negatif).
- **Problem Türü:** Bu çalışma, makine öğrenmesi paradigması çerçevesinde ikili sınıflandırma (binary classification) problemi olarak konumlandırılmaktadır. Doğrusal olmayan ve stokastik bir yapıya sahip olan finansal zaman serisi verileri, hem SVM hem de ANN algoritmalarının güçlü sınıflandırıcı özellikleri ile ele alınacaktır.
- **Fayda Sağlayacak Kullanıcı Kitlesi ve Uygulama Alanları:** Algoritmik ticaret stratejileri geliştiren bireysel yatırımcılar, portföy risk yönetimi analistleri ve yatırım bankaları başta olmak üzere; finans sektöründe karar destek sistemlerine ihtiyaç duyan tüm paydaşlar çalışmanın potansiyel faydalanıcıları arasında yer almaktadır. Öte yandan bu sistem, üniversite laboratuvar ortamında algoritmik finans uygulamalarının öğretimi için de değerli bir eğitim aracı niteliği taşıyabilecektir.

5. Literatür Taraması

Bu bölümde, hisse senedi tahmini alanındaki mevcut bilimsel literatürden özenle seçilmiş altı akademik çalışma sistematik biçimde incelenmiştir. İncelenen eserler; makale, konferans bildirisi ve literatür derleme makalesi niteliği taşımakta olup her biri yöntem, veri seti, temel bulgu, güçlü yön ve sınırlılıklar açısından ayrıntılı olarak değerlendirilmiştir.

No	Çalışma Adı	Yıl	Veri Seti	Kullanılan Yöntem	Temel Sonuç	Güçlü Yönler	Sınırlılıklar
[1]	Stock Market Prediction Using Machine Learning Techniques	2016	KSE-100 Endeksi (100 örnek, Eylül 2015 – Ocak 2016)	SLP, MLP, RBF, SVM	MLP algoritması test kümesinde %77 doğruluk oranıyla en üstün performansı sergilemiştir.	Çoklu algoritmaların aynı veri seti üzerinde karşılaştırılması ve ham veriye makroekonomik özellik (petrol fiyatı, döviz kuru) eklenmesi.	Yalnızca 100 örneklik küçük veri seti; yüksek genellenebilirlik riski mevcut.

No	Çalışma Adı	Yıl	Veri Seti	Kullanılan Yöntem	Temel Sonuç	Güçlü Yönler	Sınırlılıklar
[2]	Stock Market Prediction Using Machine Learning	2018	Yahoo Finance (NASDAQ, 1 şirket, ~900.000 kayıt)	Doğrusal Regresyon, LSTM	LSTM modeli, uzun dönem bağımlılıkları öğrenme kapasitesi sayesinde regresyon modeline kıyasla daha güvenilir sonuçlar üretmiştir.	LSTM'in zamansal bağımlılıkları modellemedeki etkinliğinin pratik olarak gösterilmesi.	Yalnızca tek bir şirkete ait veri kullanılmış; sonuçların genellenebilirliği tartışmalıdır.
[3]	A Machine Learning Model for Stock Market Prediction	2013	S&P 500 (13 şirket, Ocak 2009 – Ocak 2012)	LS-SVM, PSO, YSA (ANN-BP)	PSO ile optimize edilen LS-SVM modeli, teknik indikatörlerin katkısıyla tüm sektörlerde en düşük MSE değerine ulaşmıştır.	Teknik indikatörlerin (RSI, MACD, EMA) birlikte kullanımı ve PSO ile hiperparametre optimizasyonu.	Modelin yorumlanabilirliği düşüktür; karar süreçleri 'kara kutu' niteliği taşımaktadır.
[4]	Stock Market Prediction Using Machine Learning (IRJET)	2018	IBM Hisse Senedi (2014-2015, CSV)	SVM (RBF Kernel)	SVM algoritması aşırı öğrenme (overfitting) problemi yaşatmadan zaman serisi verisi üzerinde yüksek tahmin doğruluğu sağlamıştır.	SVM'nin sınıflandırma ve regresyon görevlerindeki esnekliği ile yüksek boyutlu uzaylardaki etkinliği.	Yalnızca tek bir hisse ve kısa bir zaman aralığı; daha geniş bir örneklem ile doğrulama yapılmamıştır.
[5]	Machine Learning Stock Market Prediction Studies: Review and Research Directions	2020	Kapsamlı Literatür Derlemesi (1999-2019, 26 makale)	ANN, SVM, Genetik Algoritmalar, Hibrit Yaklaşımlar	SVM'nin sınıflandırma problemleri için (fiyat artacak/düşecek), ANN'nin ise sayısal endeks tahmini için en uygun algoritma olduğu sonucuna ulaşılmıştır.	Sistemik literatür tarama metodolojisi; bulguların dört farklı taksonomik kategoride yapılandırılması.	Çoğu çalışmanın tek bir piyasa ve zaman dilimiyle sınırlı olması; genellenebilirlik yetersizliği.
[6]	Stock Market Prediction Using Machine Learning Techniques: A Decade Survey...	2021	Kapsamlı Literatür Derlemesi (2011-2021, Scopus, ACM, IEEE)	SVM, ANN, DNN, NB, GA, Hibrit	SVM en yaygın kullanılan algoritma olarak öne çıkmış; piyasa verisi ile metin verilerinin (sentiment) birleştirilmesinin tahmin doğruluğunu önemli ölçüde artırdığı görüldü.	Kapsamlı ve sistemik inceleme; genel bir SMP çerçevesi (generic framework) önerisi; zorluklar ve açık araştırma soruları tartışması.	Canlı test senaryolarının yetersizliği; sosyal medya bot verilerinin yarattığı gürültü sorunu.

6. İncelenen Yöntemler ve Algoritmalar

Bu bölümde akademik literatürde hisse senedi tahmini için yaygın biçimde başvurulanan yapay zeka yöntemleri teknik temelleri itibarıyla açıklanmakta; ardından bu projenin özgün bağlamı için en uygun yaklaşımın gerekçesi sunulmaktadır.

6.1. Destek Vektör Makineleri (SVM)

Destek Vektör Makineleri (Support Vector Machines – SVM), denetimli öğrenme paradigması çerçevesinde hem sınıflandırma hem de regresyon görevlerinde kullanılan güçlü bir makine öğrenmesi algoritmasıdır [4]. SVM'nin temel çalışma mantığı; n-boyutlu özellik uzayındaki veri noktalarını iki sınıf arasındaki marjini maksimize eden optimal bir hiper-düzlem (hyperplane) aracılığıyla ayırmaktır. Doğrusal olarak ayrıştırılamayan veriler için Radyal Tabanlı Fonksiyon (RBF), polinom ve sigmoid gibi çekirdek (kernel) fonksiyonları devreye girerek veriyi daha yüksek boyutlu bir uzaya taşır ve doğrusal ayrıştırılabilir hale getirir.

Finansal zaman serilerinde SVM'yi öne çıkaran temel özellik, küçük ve orta ölçekli veri setlerinde bile stabil sonuçlar üretmesi ile aşırı öğrenme (overfitting) sorununa karşı sergilediği yapısal dirençtir. Mevcut literatür, SVM'nin hisse senedi yön sınıflandırması görevlerinde tutarlı biçimde yüksek performans sergilediğini ortaya koymaktadır [1], [4], [5], [6]. Bu nedenle SVM, mevcut projenin birincil sınıflandırma algoritması olarak seçilmiştir.

6.2. Yapay Sinir Ağları (ANN) – Çok Katmanlı Algılayıcı (MLP)

Yapay Sinir Ağları (Artificial Neural Networks – ANN), biyolojik sinir sisteminden ilham alınarak geliştirilmiş hesaplama modellerinden oluşan geniş bir algoritma ailesini kapsamaktadır. Bu projede kullanılacak olan Çok Katmanlı Algılayıcı (Multilayer Perceptron – MLP) mimarisi; bir giriş katmanı, bir ya da birden fazla gizli katman ve bir çıkış katmanından oluşmaktadır. Ağırlıklar, geriye yayılım (backpropagation) algoritması aracılığıyla öğrenme sürecinde iteratif olarak güncellenmektedir.

ANN/MLP, piyasa verilerindeki doğrusal olmayan karmaşık örüntüleri modellemesi ve SVM ile karşılaştırmalı analiz yapılmasına olanak tanınması bakımından bu çalışmaya dahil edilmiştir. Literatürde MLP'nin KSE-100 endeksi üzerinde %77 test doğruluğuna ulaştığı, çok sayıda karşılaştırmalı derleme çalışmasında da güçlü bir referans algoritma olarak değerlendirildiği görülmektedir [1], [2], [5].

6.3. Teknik İndikatörler ve Özellik Mühendisliği

Özellik mühendisliği (Feature Engineering), ham OHLCV verilerinden istatistiksel ve finansal anlamlılığa sahip türetilmiş değişkenler oluşturma sürecini ifade etmektedir. Bu çalışmada uygulanacak başlıca teknik indikatörler aşağıda açıklanmıştır:

- **Göreceli Güç Endeksi (RSI – Relative Strength Index):** Belirli bir dönem içindeki ortalama kazanç/kayıp oranını kullanarak 0-100 ölçeğinde momentum ölçen bir osilatördür. $RSI > 70$ aşırı alım, $RSI < 30$ ise aşırı satım bölgesine işaret eder.
- **Hareketli Ortalama Yakınsaklık/İraksama Göstergesi (MACD):** Kısa dönem (12 günlük) ve uzun dönem (26 günlük) üstel hareketli ortalamaların (EMA) farkından hesaplanır. Trend yönü ve sinyal çizgisi kesişimleri, alım/satım sinyali üretmek için kullanılır.

- **Basit Hareketli Ortalama (SMA) ve Üstel Hareketli Ortalama (EMA):** Fiyat serisinin belirli bir pencere üzerindeki aritmetik (SMA) veya ağırlıklı (EMA) ortalamasını hesaplayarak trend yönünü tespit eder.

Literatür, teknik indikatörlerin model giriş özellik setine eklenmesinin sınıflandırma performansını anlamlı ölçüde artırdığını göstermektedir. Hegazy ve arkadaşları (2013), RSI ve MACD gibi teknik indikatörlerle optimize edilmiş LS-SVM modelinin tüm sektörlerde en düşük MSE değerine ulaştığını raporlamıştır [3]. Benzer biçimde Rouf ve arkadaşları (2021), piyasa verisi ile teknik indikatörlerin birlikte kullanıldığı modellerin, yalnızca ham fiyat verisine dayanan modellere kıyasla belirgin biçimde daha yüksek doğruluk oranları ürettiğini ortaya koymuştur [6].

6.4. Algoritma Karşılaştırması ve Proje İçin Uygunluk Gerekeşi

Mevcut proje için yapılacak algoritma seçiminde şu kriterler belirleyici olmuştur: (i) tablo formatlı zaman serisi verisiyle uyum, (ii) sınıflandırma görevindeki kanıtlanmış etkinlik ve (iii) karşılaştırmalı analiz yapılabilmesi. Bu kriterler ışığında SVM birincil algoritma, MLP ise ikincil karşılaştırma algoritması olarak belirlenmiştir. LSTM ve diğer derin öğrenme mimarileri, mevcut veri hacminin ve projenin kapsamının dışında kaldığından bu aşamada değerlendirme dışı bırakılmıştır; ancak gelecek çalışmalar için umut verici bir yön olarak not edilmiştir.

7. Veri Seti Araştırması

Hisse senedi yön tahmini için güvenilir, erişilebilir ve yüksek hacimli bir veri setine ihtiyaç duyulmaktadır. Aşağıda bu projenin gereksinimlerini karşılayan birincil ve alternatif veri kaynakları sistematik biçimde değerlendirilmiştir.

Veri Seti	Kaynak	Veri Türü	Örnek Sayısı	Hedef Değişken	Eksik Veri?	Uygunluk
AAPL – Apple Inc. Günlük Fiyat Verisi	Yahoo Finance (yfinance)	Zaman Serisi Tablosu	~25.000+ günlük kayıt (son 5 yıl)	Artış (1) / Düşüş (0)	Yok (tatil günleri hariç)	Yüksek – Seçildi
MSFT – Microsoft Corp. Günlük Fiyat Verisi	Yahoo Finance (yfinance)	Zaman Serisi Tablosu	~25.000+ günlük kayıt (son 5 yıl)	Artış (1) / Düşüş (0)	Yok	Yüksek – Alternatif
NASDAQ Composite Index Verisi	Yahoo Finance (^IXIC)	Zaman Serisi Tablosu	~10.000+ günlük kayıt	Endeks yönü	Yok	Orta – Endeks karşılaştırma için

Yukarıda belirtilen hisseler ek olarak diğer büyük ölçekli NASDAQ hisseleri de modelin eğitiminde ve genellenebilirliğini test etmek amacıyla analize dahil edilecektir.

8. Veri Ön İşleme Planı

Makine öğrenmesi modellerinin güvenilir ve önyargısız (unbiased) sonuçlar üretebilmesi, eğitim verisinin nitelikli biçimde hazırlanmasına doğrudan bağlıdır. Bu proje kapsamında uygulanacak veri ön işleme adımları aşağıda sistematik biçimde açıklanmıştır:

8.1. Özellik Çıkarımı ve Türetimi (Feature Engineering)

Ham OHLCV verisinin sınıflandırma modellerine doğrudan beslenmesi yeterli olmayacaktır. Bu nedenle ham veriden aşağıdaki türetilmiş özellikler elde edilecektir: 5, 10, 20 ve 50 günlük Basit Hareketli Ortalamalar (SMA); 12 ve 26 günlük Üstel Hareketli Ortalamalar (EMA); 14 günlük pencere ile Göreceli Güç Endeksi (RSI); MACD çizgisi, sinyal çizgisi ve histogram değerleri; günlük fiyat değişim yüzdesi (daily return); fiyat volatilitesi ve hacim değişimi göstergeleri.

8.2. Hedef Değişkenin Oluşturulması

Hedef değişken (y), $t+1$ günü kapanış fiyatının t günü kapanış fiyatından yüksek olduğu durumda 1, aksi halde 0 olarak etiketlenecektir. Bu adım, ham fiyat verisini ikili sınıflandırma problemine dönüştürmektedir.

8.3. Eksik Veri Yönetimi

Teknik indikatörlerin ilk pencere uzunluğu kadar günde değer üretememesi (örn. 50 günlük SMA için ilk 49 gün) ve borsa tatillerinin yarattığı boşluklar nedeniyle oluşacak NaN değerler tespit edilecek ve serinin başından kaldırılacaktır. Ara günlerde gerçekleşen eksik veri durumunda ileriye dönük doldurma (forward fill) yöntemi uygulanacaktır.

8.4. Veri Normalleştirilmesi ve Ölçeklendirmesi

Hacim (milyon birim), kapanış fiyatı (yüzler) ve RSI (0-100) gibi değişkenler arasındaki büyük ölçek farklılıkları, mesafeye dayalı algoritmaların performansını olumsuz etkilemektedir. Bu sorunu gidermek amacıyla tüm sayısal özellikler, sklearn kütüphanesindeki StandardScaler (ortalama 0, standart sapma 1) veya MinMaxScaler (0-1 aralığı) ile standartlaştırılacaktır.

8.5. Eğitim ve Test Kümelerinin Ayrılması

Zaman serisi verilerinin geçmişten geleceğe doğru doğrusal bir akış izlemesi nedeniyle rastgele örnekleme (random sampling) yöntemi, bilgi sızıntısına (data leakage) yol açabileceğinden uygulanmayacaktır. Bunun yerine kronolojik sıralama korunarak verinin ilk %80'i eğitim, son %20'si ise test kümesi olarak ayrılacaktır. Hiperparametre optimizasyonu için zaman serisi çapraz doğrulaması (TimeSeriesSplit) uygulanması planlanmaktadır.

9. Önerilen Proje Yaklaşımı

Projenin teknik uygulama altyapısı Python programlama dili üzerine inşa edilecektir. Veri toplama için yfinance, veri manipülasyonu ve indikatör hesaplamaları için pandas ve ta-lib, model geliştirme ve değerlendirme için scikit-learn ve tensorflow/keras kütüphaneleri kullanılacaktır. Geliştirme ortamı olarak Jupyter Notebook tercih edilecektir.

- Aşama 1 – Veri Toplama: yfinance API'si aracılığıyla belirlenen en yüksek hacimli NASDAQ hisselerine ait günlük OHLCV verileri çekilerek kronolojik sırayla tek bir veri seti haline getirilecektir.

- Aşama 2 – Özellik Mühendisliği: Ham veriye RSI, MACD, SMA ve EMA indikatörleri hesaplanarak eklenerek zenginleştirilmiş özellik matrisi oluşturulacaktır.
- Aşama 3 – Ön İşleme: Hedef değişken oluşturulacak, veri standartlaştırılacak ve eğitim/test kümeleri kronolojik sıraya göre bölünecektir.
- Aşama 4 – Model Eğitimi: SVM (RBF kernel) ve MLP (Çok Katmanlı Algılayıcı) modelleri eğitim verisi üzerinde bağımsız olarak eğitilecektir. Her iki model için hiperparametre optimizasyonu, Grid Search ile gerçekleştirilecektir.
- Aşama 5 – Performans Değerlendirmesi: Her iki modelin test kümesi üzerindeki performansı, Bölüm 10'da tanımlanan metrikler kullanılarak karşılaştırmalı biçimde raporlanacaktır.
- Aşama 6 – Paper Trading Simülasyonu: Seçilen model, bir haftalık gerçek zamanlı (ya da tarihsel) veri üzerinde sanal hesap ortamında test edilecek ve ticari uygulanabilirlik analizi yapılacaktır.
- Aşama 7 – Kullanıcı Arayüzü (Opsiyonel): Projenin sonunda tahmin sonuçlarını interaktif biçimde görselleştiren, kullanıcı dostu bir web arayüzünün Streamlit framework'ü ile geliştirilmesi planlanmaktadır.

10. Model Değerlendirme Ölçütleri

Bu çalışmada hisse senedi yön tahmini ikili sınıflandırma (binary classification) problemi olarak modellendiğinden model başarısının tek bir metrikle değerlendirilmesi yetersiz kalacaktır. Piyasa verilerinde sınıf dengesizliği yaşanabileceği de dikkate alınarak çok boyutlu bir değerlendirme çerçevesi benimsenmiştir.

10.1. İstatistiksel Sınıflandırma Metrikleri

- **Doğruluk (Accuracy):** Toplam tahminler içinde doğru sınıflandırılan örneklerin oranı. Sınıf dengesizliği durumunda tek başına yanıltıcı olabilir.
- **Kesinlik (Precision):** Pozitif (Artış) olarak tahmin edilen örnekler içinde gerçekten pozitif olanların oranı. Yanlış pozitif (false positive) işlem sinyallerini minimize etmek açısından kritiktir.
- **Duyarlılık / Geri Çağırma (Recall / Sensitivity):** Gerçek pozitif örnekler içinde doğru tespit edilenlerin oranı. Kaçırılan karlı fırsatların minimize edilmesi için önem taşır.
- **F1-Skoru (F1-Score):** Kesinlik ve duyarlılığın harmonik ortalaması. Dengesiz veri setleri için Accuracy'ye alternatif ve daha güvenilir bir bileşik metriktir.
- **Karmaşıklık Matrisi (Confusion Matrix):** Doğru pozitif (TP), Yanlış Pozitif (FP), Yanlış Negatif (FN) ve Doğru Negatif (TN) değerlerini görselleştirerek modelin hata örüntülerini analiz etmeye olanak tanır.
- **ROC-AUC Skoru:** Sınıflandırıcının farklı eşik değerlerindeki performansını karşılaştırmak ve iki modelin genel ayırım kapasitesini değerlendirmek için kullanılacaktır.

10.2. Paper Trading ile Pratik Uygulanabilirlik Değerlendirmesi

Bir hisse senedi tahmin modelinin akademik performansı, pratikte finansal kazanç yaratıp yaratmadığını garanti etmez. Bu olgusal boşluğu kapatmak amacıyla geliştirilen modeller, yukarıda sıralanan istatistiksel değerlendirme adımlarının ardından sanal hesap (paper trading) ortamında pratik bir sınava tabi tutulacaktır.

Bu süreçte model, gerçek veya son bir haftaya ait tarihsel NASDAQ verisi üzerinde çalıştırılacak; ürettiği alım (1) ve satım (0) sinyallerine karşılık gelen sanal işlemler kaydedilecektir. İşlem maliyetleri ve spread dikkate alınarak simüle

edilen portföyün haftanın başı ile sonu arasındaki kümülatif getirisi (kar/zarar) hesaplanacak ve bir temel strateji (buy-and-hold) ile karşılaştırılacaktır. Bu analiz; modelin gerçek dünya finansal ortamındaki pratik uygulanabilirliğini, karar kalitesini ve algoritmik ticaret senaryolarına uygunluğunu raporun ayrı bir alt bölümünde kapsamlı biçimde sunacaktır.

11. Beklenen Sonuçlar

Projenin başarıyla tamamlanması durumunda elde edilmesi beklenen çıktılar ve katkılar aşağıda belirtilmiştir:

- **Çalışan Sınıflandırma Modeli:** Geçmiş fiyat ve hacim hareketlerini, teknik indikatör özellikleriyle birleştirerek NASDAQ hissesinin ertesi günkü trend yönünü tahmin eden, performansı ampirik olarak değerlendirilmiş bir makine öğrenmesi modeli geliştirilecektir.
- **Karşılaştırmalı Algoritma Analizi:** SVM ve MLP algoritmalarının finansal zaman serisi sınıflandırma görevindeki güçlü ve zayıf yönleri, çok boyutlu performans metrikleri aracılığıyla ortaya konacaktır.
- **Özellik Mühendisliğinin Katkısının Belirlenmesi:** Teknik indikatörlerin model başarısına olan istatistiksel katkısı, ham OHLCV verisiyle karşılaştırmalı deneylerle ölçülecektir.
- **Paper Trading Simülasyon Raporu:** Sanal hesap ortamındaki kar/zarar analizi, modelin algoritmik ticaret senaryolarındaki pratik uygulanabilirliğini gösterecektir.
- **Sınırlılıklar ve Gelecek Çalışmalar:** Modelin, Etkin Piyasa Hipotezi ve öngörülemeyen makro-ekonomik şoklar (siyasi krizler, salgın hastalıklar vb.) karşısındaki kısıtları akademik dürüstlük çerçevesinde raporlanacaktır. Bu sistem, kesin finansal tavsiye niteliği taşımayan algoritmik olasılık çıkarımı yapan analitik bir araç olarak tanımlanacaktır.

Sonuç olarak bu projenin, makine öğrenmesi tabanlı finansal tahmin alanındaki bilimsel literatüre katkıda bulunması ve gerçek dünya uygulamalarına yönelik somut bir metodolojik çerçeve sunması beklenmektedir.

12. Kaynakça

1. Usmani, M., Adil, S. H., Raza, K., & Ali, S. S. A. (2016). Stock Market Prediction Using Machine Learning Techniques. 3rd International Conference On Computer And Information Sciences.
2. Parmar, I., Agarwal, N., Saxena, S., et al. (2018). Stock Market Prediction Using Machine Learning. First International Conference on Secure Cyber Computing and Communication (ICSCCC).
3. Hegazy, O., Soliman, O. S., & Salam, M. A. (2013). A Machine Learning Model for Stock Market Prediction. International Journal of Computer Science and Telecommunications, 4(12).
4. Reddy, V. K. S. (2018). Stock Market Prediction Using Machine Learning. International Research Journal of Engineering and Technology, 5(10).
5. Strader, T. J., Rozycki, J. J., Root, T. H., & Huang, Y. H. J. (2020). Machine Learning Stock Market Prediction Studies: Review and Research Directions. Journal of International Technology and Information Management, 28(4).
6. Rouf, N., Malik, M. B., Arif, T., et al. (2021). Stock Market Prediction Using Machine Learning Techniques: A Decade Survey on Methodologies, Recent Developments, and Future Directions. Electronics, 10(2717).